



Optimización de Estrategias de Ventas en Amazon

(con Pandas)

Inteligencia Artificial y Big Data
Big Data Aplicada

DAVID CUELI CHAVARRÍA

En **AZUL** los textos de los enunciados.

En **NEGRO** las respuestas.

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

ÍNDICE

Contexto	4
EJERCICIO 1	4
Proyecto KDD	4
Resumen ejecutivo	4
Objetivo del proyecto	4
Contexto y alcance	5
Metodología	5
Infraestructura técnica	5
Entorno de trabajo	5
Herramientas de análisis	6
Datos utilizados y calidad	6
Limpieza de datos	7
Auditando Categorías (columna <i>category</i>)	7
Análisis y hallazgos	11
Auditoría de Calidad y Consistencia del Dataset	11
Trazabilidad de Reseña Única (user_id + review_id + product_id)	11
Depuración de duplicados relacionales	13
Verificación de duplicados relacionales	14
Auditoría de datos Null	14
Minería de datos	16
Estructura de Catálogo de Precios	16
El Núcleo del Catálogo, el consumo masivo	17
Naturaleza de los Casos atípicos coherentes	17
Conclusiones	18
Recomendaciones	18
Auditoría de Popularidad para la Asignación de Presupuesto (Evitar Falsos Éxitos)	18
Estrategia de Venta Cruzada para el Núcleo del Catálogo (Consumo Masivo)	19
Segmentación de Alta Tecnología para los Casos Atípicos Coherentes (Gama Alta)	19
Limitaciones	19
Calidad del texto en las reseñas.....	19
Ausencia de datos temporales o de coste	19
Conclusiones	19
Importancia de la auditoría de datos	19
Validación del enfoque cuantitativo.....	19
Realidad del inventario analizado.....	20
Anexo	20

Contexto [-Ir al índice-](#)

EJERCICIO 1

Proyecto KDD

Optimización de Estrategias de Ventas en Amazon (con Pandas)

Utilizar el conjunto de datos de ventas de Amazon y la librería Pandas para realizar un análisis KDD completo, identificar insights valiosos y recomendar estrategias de ventas y marketing para Amazon.

Dataset: "Amazon Sales Dataset" (<https://www.kaggle.com/datasets/karkavelrajaj/amazon-sales-dataset/data>).

Se debe realizar un seguimiento de todas las fases del modelo KDD para conseguir extraer información útil del Dataset.

La entrega será capturas de pantallas del proceso y código utilizado y un pequeño texto explicando los resultados y pasos.

Resumen ejecutivo [-Ir al índice-](#)

Como dicta el enunciado, para la presente práctica aplicamos el proceso KDD (Knowledge Discovery in Databases) sobre el conjunto de datos de ventas de Amazon (*Amazon sales en <https://www.kaggle.com/datasets/karkavelrajaj/amazon-sales-dataset/data>*) con el objetivo de realizar principalmente un estudio sobre la reputación digital y la percepción que los clientes tienen a partir de valoraciones, volumen de opiniones, precios, descuentos y contenido textual de reseñas.

El trabajo se centra en dos ejes, por un lado, la reputación y percepción del cliente y por otro, la relación entre precio, descuento, valoración y su volumen. Identificaremos qué productos reciben mejor aceptación, qué rangos de precio parecen más asumidos por los consumidores y qué patrones discursivos aparecen en los comentarios.

Aunque el Dataset incorpora variables económicas como ***actual_price***, ***discounted_price*** y ***discount_percentage***, pero no incluye ventas reales, por lo que no resulta metodológicamente correcto interpretarlo o anunciarlo como un conjunto de datos de venta de Amazon.

Además, la calidad estructural del dato presenta una limitación bastante significativa —*a título personal, casi insalvable*— ya que varias de columnas asociadas a usuarios y reseñas aparecen agrupadas en una única fila por producto mediante texto separado por (,), lo que compromete la trazabilidad exacta entre identificador de usuario, de reseña, título y contenido de cada reseña.

Los resultados finales revelan una polarización muy pronunciada del catálogo, concentrando más del 97% de las referencias en apenas tres categorías: *Electronics*, *Computers&Accessories* y *Home&Kitchen*. Asimismo, la auditoría de calidad delata severas deficiencias estructurales en el Dataset original, identificando fallos de extracción que duplican reseñas de forma artificial al expandir los registros relacionales. Además los análisis no han podido centrarse realmente en las ventas ya que el Dataset posee una ausencia total de variables de conversiones, movimientos de compra y temporales —*no entiendo cómo el Dataset se llama Amazon Sales*—, que descarta cualquier análisis de ventas, adquisiciones y estacionalidad.

Objetivo del proyecto [-Ir al índice-](#)

El objetivo principal del informe es evaluar cómo se construye la percepción del cliente sobre los productos analizados a partir de sus valoraciones cuantitativas y de sus comentarios textuales, identificando patrones de satisfacción, queja, utilidad percibida y relación calidad-precio.

De forma complementaria, se pretende examinar la posible asociación entre variables como ***discounted_price***, ***discount_percentage***, ***rating*** y ***rating_count***, con el fin de detectar señales de aceptación dentro del catálogo.

Como ya he comentado anteriormente, no se persigue estimar ventas, demanda, ni rendimiento económico, ya que el Dataset no contiene variables relativas a transacciones que permitan analizar ese tipo de información con rigor.

Contexto y alcance [-Ir al índice-](#)

Este proyecto se desarrolla en el contexto del *módulo de Big Data Aplicado* del *Máster de Formación Profesional en Inteligencia Artificial y Big Data*, y cuya finalidad tiene como objetivo *integrar los conceptos de Inteligencia de Negocios y del proceso KDD* con un caso práctico de análisis de datos “reales” sobre un conjunto de datos de ventas de Amazon —*a título personal, casi insalvable*—.

El Dataset utilizado corresponde a un conjunto de datos de “ventas de Amazon” disponible públicamente en la plataforma Kaggle, que incluye información sobre productos, precios y valoraciones de clientes.

El alcance del trabajo se centra en el análisis exploratorio de dicho Dataset —*realista o no*—, de valoraciones de productos por usuario, para la generación de información valiosa de negocio. Se abordarán de forma sistemática las fases de un proceso ETL, donde la *Extracción* pasa a ser la **Selección**. *Transformación* será desglosada en **limpieza**, **transformación** —*valga o no la redundancia*— y **minería de datos**. La *Carga* serán los datos ya procesados, pero no se escribirán en el sistema de destino, sino que vamos a hacer un análisis completo interpretándolos para su correspondiente señalización de resultados valiosos en la propuesta de recomendaciones de BI orientadas a la toma de decisiones estratégicas en ventas y marketing, según juicio.

Metodología [-Ir al índice-](#)

La metodología seguida combina una fase inicial de revisión exploratoria visual con una fase posterior de depuración conceptual y análisis estructural del Dataset.

Al observar el tamaño del Dataset, inicialmente, se realizó una primera inspección visual mediante Excel, útil para ver la forma de las columnas, detectar patrones repetidos y advertir problemas de formato que no siempre son evidentes en una lectura automatizada.

Esta observación preliminar permitió identificar que columnas como **user_id**, **user_name**, **review_id**, **review_title** y **review_content**, que contienen largas cadenas de texto con múltiples elementos separados por (,) dentro de una misma fila, sugiere que varias reseñas de un mismo producto fueron agrupadas en un único registro. Este diseño introduce un problema crítico de consistencia, ya que la coma parece utilizarse simultáneamente como separador estructural y gramatical dentro del propio contenido textual, lo que dificulta distinguir con fiabilidad dónde termina un elemento y dónde empieza el siguiente.

Desde un punto de vista técnico, para realizar un análisis real por usuario o por reseña sería necesario “explotar” esas listas y reconstruir una observación por unidad individual. Sin embargo, una explosión múltiple de varias columnas a la vez no garantiza alineación correcta entre IDs, nombres, títulos y contenidos si alguna de las listas contiene un elemento de más o de menos, lo que puede producir desajustes irreversibles entre usuario y comentario y la información quedaría inservible.

Por todo esto, la estrategia metodológica adoptada en este informe parte del aprovechamiento de los campos que son verdaderamente fiables a nivel producto y de una lectura crítica de los campos textuales allí donde su uso siga siendo interpretable.

En consecuencia, el análisis se orienta a relaciones entre precio, descuento, valoración y su volumen, así como a la detección de patrones cualitativos generales en los comentarios, evitando afirmaciones que requieran una correspondencia exacta fila-reseña que el Dataset no asegura.

Infraestructura técnica

El análisis se ha desarrollado sobre una estación de trabajo equipada con dos procesadores Intel(R) Xeon(R) CPU E5-2699 v4 @ 2.20 GHz, 256 GB de memoria RAM DDR4, tarjeta gráfica NVIDIA GeForce RTX 3060 de 12 GB y almacenamiento de 4,16 TB totales, de los cuales se encontraban en uso 1,66 TB. El sistema operativo principal es Windows 11 Pro de 64 bits, versión 24H2, con arquitectura basada en x64.

Entorno de trabajo

El entorno de desarrollo se ha configurado bajo Debian GNU/Linux 13 (trixie) bajo WSL, donde se utiliza el terminal de comandos zsh 5.9 como interfaz. La gestión del entorno de Python se ha realizado con pyenv 2.6.8, teniendo como intérprete activo Python 3.13.7. Para determinadas tareas de despliegue, encapsulado y consistencia del entorno, se ha utilizado Docker Desktop en Windows, versión 29.5.2.

Herramientas de análisis

Para la inspección inicial del conjunto de datos y la validación visual de la estructura de las columnas se ha empleado Microsoft Excel, especialmente en la fase de revisión exploratoria.

Autoguardado

amazon.sales.csv

Buscar

ArchivoInicioInsertar

Disposici3n de p1ginaF3rmulasDatosRevisarVistaAutomatizarProgramadorAyudaAcrobat

Dise1o de tablaConsultas

ComentariosCompartir

Pegar

Cortar

Copiar

Copiar formato

Portapapeles

Aptos Narrow

11

A

A

N

K

S

Fuente

Alineaci3n

Ajustar texto

Combinar y centrar

General

N3mero

Formato condicional

Dar formato como tabla

Estilos de celda

Insertar

Eliminar

Formato

Celdas

Autosuma

Reellenar

Borrar

Ordenar y filtrar

Buscary seleccionar

Sensibilidad

Complementos

Crear un PDF

K3

ArKn,Nirbhay kumar,Sagar Viswanathan,Asp,Placcholder,Bharant,sonia,Niam

A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q
product_id	product_name	category	discounted_price	actual_price	discount_percentage	rating	rating_count	about_product	user_id	user_name	review_id	review_title	review_content	img_link	product_link	
B07JW9HJ1	Wayona Nylon Brai Computers&A	Computers&A	€399	€1,099		0.64	42 24,269	High Compatibility AG3D6C4STAK Manav,Adarsh g R3HXW10LRPUNMF,R2A Satisfied,Charging Looks durable Chargi	https://m.mec	https://www.amazon.in/Wayona-Bre						
B096N86PVG	Ambrane Unbreaka Computers&A	Computers&A	€199	€349		0.43	40 43,994	Compatible with all AECPPYFQVRi ArdKn,Nirbhay k RGIEQG07R9HSZ,R1SMV A Good Braided Ca l ordered this cable t	https://m.mec	https://www.amazon.in/Ambrane-Un						
B096MSW6CT	Source Fast Phone Computers&A	Computers&A	€199	€1,899		0.9	39 7,928	Fast Charger& D AGU3BBQZV2I Kunal,Himanshi R3J3EQQ9T26Z1,R3JEW Good speed for rea Not quite durable an	https://m.mec	https://www.amazon.in/Source-IPh						
B08HDJ86NZ	boAt Deuce USB 30 Computers&A	Computers&A	€329	€699		0.33	42 94,363	The boAt Deuce US1 AEWAZDZJLQ Omkar dhale,J R3EEUZXKK9J361,R3HJV Good product,Goo Good product,Long w	https://m.mec	https://www.amazon.in/Deuce-300-f						
B08CF3B7N1	Portronics Connect Computers&A	Computers&A	€154	€399		0.61	42 16,905	[CHARGE & SYNC FL AEG3Q6KXSK5F rahulss6099,Swa R1BP4L2HH9TFUP,R16P As good as origina Bought this instead o	https://m.mec	https://www.amazon.in/Portronics-t						
B08Y1TFS96	pTron Solero TB301 Computers&A	Computers&A	€149	€1,000		0.85	39 24,871	Fast Charging & Da AEQ2YMXSZW Jayesh,Rajesh k.R7S8ANNSDPM40,R3CLZ It's pretty good,Awe It's a good product.L	https://m.mec	https://www.amazon.in/Solero-TB30						
B08WRWPM22	boAt Micro USB 55 T Computers&A	Computers&A	€176.63	€499		0.65	41 15,188	It Ensures High Spe AG706DAADC Vivek Kumar,Am R8E73K2KWRD5,RSD0J Long durable..gool Build quality is good	https://m.mec	https://www.amazon.in/boAt-Micro-						
B08DDRGWUJ	MI Usb Type-C Cabl Computers&A	Computers&A	€229	€299		0.23	43 30,411	1m long Type-C USE AHW6ESLQ2B1 Pavan A H,Jayes R2X09D1YHACKR,R32Z Worth for money - i Worth for money - sui	https://m.mec	https://www.amazon.in/MI-MTCY001						
B0808FXQFU	TP-Link USB WiFi Ai Computers&A	Computers&A	€499	€999		0.5	42 1,79,691	USB WiFi Adapter – AGV3IEFANZC Azhar Ju,Man,An R1LW6NWSVTVZ2H,R3V Works on linux for i use this to connect t	https://m.mec	https://www.amazon.in/TP-Link-TL-V						
B082LZGK39	Ambrane Unbreaka Computers&A	Computers&A	€199	€299		0.33	40 43,994	Universal Compatit AECPPYFQVRi ArdKn,Nirbhay k RGIEQG07R9HSZ,R1SMV A Good Braided Ca l ordered this cable t	https://m.mec	https://www.amazon.in/Ambrane-Un						
B08CF3D7QR	Portronics Connect Computers&A	Computers&A	€154	€339		0.55	43 13,391	[CHARGE & SYNC FL AEG3Q6KXSK5F Tanya,Anu,Aksh R11MQS7WD9C310,R2AI Good for fast charg The cable is efficient	https://m.mec	https://www.amazon.in/Portronics-f						
B0789JZTJC	boAt Rugged V3 Extr Computers&A	Computers&A	€299	€799		0.63	42 94,363	The boAt rugged ca AEWAZDZJLQ Omkar dhale,J R3EEUZXKK9J361,R3HJV Good product,Goo Good product,Long w	https://m.mec	https://www.amazon.in/Rugged-Extr						
B07K8MBL2H	AmazonBasics Flexi Electronics (H	Electronics (H	€219	€700		0.69	44 26,973	Flexible, lightweight AEV16JZPQ Rishav Gossain, R1FKOKZ3HKHJBZ,R2Wl It's quite good and I am using it for 14 da	https://m.mec	https://www.amazon.in/AmazonBas						
B085DTN6R2	Portronics Connect Computers&A	Computers&A	€350	€899		0.61	42 2,262	[20W PD FAST CHARG AGUAYQHARA Priya,Mansi,Plal R1QETDIPRCX4S0,PARQ Works,Nice Produ Definitely isn't as go	https://m.mec	https://www.amazon.in/Portronics-t						
B09KLVMZB3	Portronics Connect Computers&A	Computers&A	€159	€399		0.6	41 4,768	[CHARGE & SYNC FL AEP2XV07UB Deepaak Singh, R20XIOU25HEX80,R2X5I Great but,Worked v Looing charging cab	https://m.mec	https://www.amazon.in/Portronics-t						
B07332NJK3	MI Braided USB Typ Computers&A	Computers&A	€349	€399		0.13	44 18,757	1M Long Cable. Usit AGSGSRTEZBC Birendra ku R21PQNKCOE10UK,RQIE Good product,usin I like it ((Best ch	https://m.mec	https://www.amazon.in/MI-Braided-						
B086F7JX4C	MI 80 cm (32 inches Electronics (H	Electronics (H	€13,999	€24,999		0.44	42 32,840	Note - The brands, I AHEVOQADIS Manoj madhnes R13UTIA6KOF6QV,R2UC It is the best tv if yo Pros- xiami 5a is bes	https://m.mec	https://www.amazon.in/MI-Inches-R						
B082LSV4H9	Ambrane Unbreaka Computers&A	Computers&A	€249	€399		0.38	40 43,994	Compatible with all AECPPYFQVRi ArdKn,Nirbhay k RGIEQG07R9HSZ,R1SMV A Good Braided Ca l ordered this cable t	https://m.mec	https://www.amazon.in/Ambrane-Un						
B08WRBGSXW	boAt Type C A325 T Computers&A	Computers&A	€199	€499		0.6	41 13,045	Type C A 325 Cable I AFB8KJRAQ5FI Rohan Narkar, J R2BP8Y5OJXKJF,R2188 Good for charging . Check for offera befor	https://m.mec	https://www.amazon.in/boAt-A325-T						
B080DLMG6T	LG 80 cm (32 inchet Electronics (H	Electronics (H	€13,490	€21,990		0.39	43 11,976	Resolution: HD Rea AHB8NK874L G1 NIRMAL,M,Mano R2PN68G0BQ62F,R31J Sound quality,Very LG was always Good	https://m.mec	https://www.amazon.in/LG-Inches-R						
B0906HXFC1	Duracell USB Lightn Computers&A	Computers&A	€970	€1,799		0.46	45 8,105	Supports los Devic AF9YBIBWJUL Prasanannai,Jayar R12D1BZF9MU8TN,R32J Good cable for car,I trust this product! V	https://m.mec	https://www.amazon.in/DURACELL-L						
B085194JFL	tizum HDMI to VGA. Electronics (H	Electronics (H	€279	€499		0.44	37 10,962	Superior Stability: EAE05FHWNNOC aditya d.,Parant R1GYK05NN67470,R1J2 Good product ; Ave This connector has p	https://m.mec	https://www.amazon.in/Adapter-Pro						
B09F6S8BT6	Samsung 80 cm (32 Electronics (H	Electronics (H	€13,490	€22,900		0.41	43 16,299	Resolution: HD Rea AHEV04Q5NN Rahman Ali,Parant R1SN0D4DFBKAZI,R15X Good,Sound is very Overaall good..TV pic	https://m.mec	https://www.amazon.in/Samsung-In						
B08NHVHC99	Flux Micro Usb Cabl Computers&A	Computers&A	€59	€199		0.7	40 9,378	Micro usb cable is AHKIUDTVJ4T\$@ 1 TOS - ,Se R3F4T5TRYPTMIG,R3DQ Worked on iPhone Worked on iPhone 7 i	https://m.mec	https://www.amazon.in/Flux-Micro-C						
B081VVCYZY	Acer 80 cm (32 inch Electronics (H	Electronics (H	€11,499	€19,990		0.42	43 4,703	Resolution: HD Rea AFSM5HGEYDY Ayush,ROHIT A, R1EB83566VCSCG,R24M Wonderful TV and / About the TV - Wonde	https://m.mec	https://www.amazon.in/Acer-Inches						
B01M4G5IVU	Tizum High Speed t Electronics (H	Electronics (H	€199	€699		0.72	42 12,153	Latest Standard HD AGVUE2FN2I Yashpreet Singh R2D1HMHOPYEASB,R24I Cheap product and The signal is too uns	https://m.mec	https://www.amazon.in/TIZUM-Slim-						
B08B42LWKN	OnePlus 80 cm (32 Electronics (H	Electronics (H	€14,999	€19,999		0.25	42 34,899	Resolution: HD Rea AFUT7TANZTY ATHARVA BOND1 R3C0VOP2R7Z28,R2T6 Worthy and most a This OnePlus TV is gr	https://m.mec	https://www.amazon.in/OnePlus-inc						
B094JNXXNPV	Ambrane Unbreaka Computers&A	Computers&A	€299	€399		0.25	40 2,766	Blazing Charging - AFYR830TBUX Anand sarma,J R249YCVKYR5XD,R1GH Ok cable,three pin The product seems ai	https://m.mec	https://www.amazon.in/Ambrane-Un						
B08W5X9BRT	Duracell USB C To L Computers&A	Computers&A	€970	€1,999		0.51	44 184	1.2M Tangle Free di AHZWIKVEIE7 Amazon Custom R1Y3KJUV4V3QF4,RK3D Very good product. Fast charging..Cable	https://m.mec	https://www.amazon.in/Duracell-Lig						

Figura 1

Se puede observar claramente en la [Figura 1](#) cómo las columnas **user_id**, **user_name**, las columnas de reseñas (**reviews_***), ID, Title y Content están segmentadas por el carácter (,) lo que hace que sea necesario “explotar” esas listas y reconstruir una observación por unidad individual. Sin embargo, como ya comentamos antes, la explosión múltiple de varias columnas a la vez no garantiza alineación correcta entre IDs, nombres, títulos y contenidos, ya que si alguna de las listas contiene un elemento de más o de menos, puede producir desajustes irreversibles entre usuarios y comentarios y la información quedaría inservible.

Más adelante, en cada sección, se usarán otras herramientas para el tratamiento de datos, cálculo y visualización que permitan una explotación rigurosa de la información y se incorporan y documentarán mediante capturas de pantalla para dejar constancia del proceso y del resultado obtenido.

Datos utilizados y calidad [-Ir al índice-](#)

El conjunto de datos utilizado incluye identificadores y nombres de producto, categorías, precio actual, porcentaje de descuento, valoración, contador de valoraciones, descripción del producto, identificadores de usuario, nombres de usuario, identificadores de reseña, títulos de reseña, contenido de reseña, enlaces de imagen y enlaces al producto.

No obstante, la calidad del dato queda claramente resentida en la parte relativa a usuarios y reseñas ya que la agrupación de múltiples observaciones dentro de una sola fila, unida al uso de (,) como delimitador no protegido por un encapsulamiento como puede ser mediante ("), impide asegurar la integridad relacional entre varias columnas textuales y compromete cualquier análisis fino a nivel individual.

Por tanto, puedo considerar que el Dataset es **apto pero con reservas** para análisis descriptivos de reputación, percepción y relaciones entre variables numéricas visibles, ya que presenta limitaciones severas para minería de opiniones por usuario.

Aunque la circunstancia, no me invalida el informe, sí me obliga a indicar y a insistir, que los hallazgos deberán interpretarse dentro de un marco exploratorio cauteloso, donde se aprovechan únicamente la información cuya consistencia resulta razonablemente defendible.

Limpieza de datos -Ir al índice-

Al observar el resultado de `df.info()`, se detecta el típico problema técnico de tipo de dato, que no es otra que las todas las columnas son de tipo (texto), incluso campos que deberían ser numéricos como **discounted_price**, **actual_price**, **discount_percentage**, **rating** y **rating_count**. Además, **rating_count** tiene dos valores nulos (1463 no nulos frente a 1465 totales).

Como son muy pocas filas, y soy de la vieja escuela, al abrir el *Dataset* con aplicación de hojas de cálculo, se ve claramente que el formato regional del *Dataset* es de la India (por el dominio *.in* en las URL de los productos y más que nada por la moneda (₹) que aparece en las columnas de precios).

Por todo esto habrá que hacer la limpieza de los datos de columnas que detallo a continuación:

- Eliminaremos completamente las comas (,), ya que actúan exclusivamente como separadores de miles.
- Como el punto ya es el separador decimal correcto en este formato regional, lo mantendremos.
- Eliminaremos cualquier carácter que no sea un dígito como por ejemplo la moneda (₹) o el porcentaje (%).
- Si existen valores problemáticos que no se pueden transformar en número, los convertimos a **NaN**.

Al haber aplicado conversiones de tipo forzadas `errors='coerce'` en el método `to_numeric()` de *Pandas* en los pasos anteriores ([Limpieza de datos](#)) dentro de la función:

```
# =====  
# DataFrame CleanRegionalFormat  
# -----  
# Limpia y convierte columnas numéricas basadas en el formato regional original punto para decimales,  
# (,) para miles, símbolos de moneda como (₹) o porcentaje (%).  
#  
# @param DataFrame pDfIn El marco de datos original con los datos de Amazon en bruto.  
# @return DataFrame DataFrame con las columnas numéricas parseadas correctamente.  
# -----  
def CleanRegionalFormat(pDfIn: pd.DataFrame):  
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Cualquier carácter **NaN** en el origen (como celdas vacías o el carácter ()) que suele aparecer en la columna **rating** de este *Dataset* de Amazon) se habrá transformado automáticamente en un **NaN** limpio.

Más adelante, una vez estén explotados las columnas **category**, **user_id** y **review_id**, tocará localizarlos y hacer de nuevo una limpieza.

Auditando Categorías (columna *category*) -Ir al índice-

La columna *category* es una columna de texto que contiene una estructura jerárquica profunda separada por el carácter (|), por ejemplo:

Categoría 1| Categoría 2|...| Categoría N.

Primeramente, vamos a auditarla para que nos ofrezca alguna información de utilidad y si es posible explotarla para separar las categorías mediante el método *One-Hot Encoding*.

A continuación vamos a ejecutar el siguiente análisis para que nos muestre la estructura anidada real de las categorías de productos en el momento de la extracción de datos al *Dataset* del CSV

```
# =====  
# DataFrame AuditCategoryColumn  
# -----  
# Analiza la estructura y volumen de registros en la columna category.  
#  
# @param DataFrame pDfIn el marco de datos actual.  
# -----  
def AuditCategoryColumn(pDfIn: pd.DataFrame):  
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Como podemos comprobar, el análisis nos muestra los primeros registros del Dataset para la variable **category** y confirmamos la estructura anidada mediante la **barra vertical** (|).

```
+ =====
+ Category Column Structural Audit
+ -----
+ Valores nulos en categoría: 0
+ Combinaciones de categorías únicas en bruto: 211
+
+ Muestra de los primeros registros de la columna en bruto:
0   Computers&Accessories|Accessories&Peripherals|...
1   Computers&Accessories|Accessories&Peripherals|...
2   Computers&Accessories|Accessories&Peripherals|...
3   Computers&Accessories|Accessories&Peripherals|...
4   Computers&Accessories|Accessories&Peripherals|...
Name: category, dtype: object
+
+ Total execution time (Category Audit)
+ -----
0.0028 seconds
+ =====
+
```

Igualmente podemos ver la existencia de una alta dispersión inicial en la variable, **registrando un total de 211 combinaciones**, así que vamos a explotar los valores de la columna **category** para intentar conseguir una reducción de la dimensionalidad, consolidando el Dataset en **categorías principales**.

Una vez que ya conocemos la estructura de la variable **category**, podemos comenzar con la explosión de las combinaciones encontradas mediante el siguiente método.

```
# =====
# DataFrame GetCategories
# -----
# Extrae la jerarquía de categorías para facilitar la agrupación
#
# @param DataFrame pDfIn DataFrame con la columna category original.
# @return DataFrame con la nueva columna categórica simplificada.
# -----
def GetCategories(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

El resultado del análisis es el siguiente:

```
+ =====
+ Category Transformation - Main Category Extraction
+ -----
+ Volumen de nuevas categorías principales únicas: 9
+
+ Distribución de productos por categoría raíz:
main_category
Electronics           526
Computers&Accessories 453
Home&Kitchen          448
OfficeProducts        31
MusicalInstruments     2
HomeImprovement        2
Toys&Games             1
Car&Motorbike          1
Health&PersonalCare    1
Name: count, dtype: int64
+
+ Total execution time (Category Transformation)
+ -----
0.0122 seconds
+ =====
```




Figura 2a

De lo que podemos deducir que se ha logrado una reducción drástica de la dimensionalidad, que es lo que estábamos buscando y así, consolidamos el Dataset en **9 categorías principales**.

Además se observa una asimetría crítica en la distribución de los productos con tres categorías claramente dominantes el conjunto de datos (*Figura 2*):

1. *Electronics* con **526 registros**
2. *Computers&Accessories* con **453 y**
3. *Home&Kitchen* con **448**

Acumulando entre las tres **más del 97%** del total de las observaciones. **Las 6 categorías restantes** muestran una presencia **por debajo de 31 registros cada una**. Esta concentración **justifica la simplificación aplicada del método One-Hot Encoding**, ya que si hubiésemos aplicado esta técnica sobre las *211 ramas originales* habría provocado un problema de *dispersión de datos* y un *aumento artificial de la dimensionalidad*, penalizando el rendimiento de cualquier modelo posterior. Y si aplicamos la función:

```
# =====  
# DataFrame EncodeCategories  
# -----  
# Aplica One-Hot Encoding sobre la columna main_category para preparar el Dataframe para minería de datos.  
#  
# @param DataFrame pDfIn DataFrame con la columna main_category ya limpia.  
# @return DataFrame DataFrame con las nuevas columnas binarias integradas.  
# -----  
def EncodeCategories(pDfIn: pd.DataFrame):  
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Obtenemos el siguiente resultado:

```
+ =====  
+ Category Transformation - One-Hot Encoding  
+ -----  
+ New binary columns added: 9  
+ Total columns in current DataFrame: 27  
+  
+ Sample of the newly generated categorical columns:  
   cat_Car&Motorbike  cat_Computers&Accessories  cat_Electronics  cat_Health&PersonalCare  cat_Home&Kitchen  [...]  
0                  0                        1                  0                  0                  0  
1                  0                        1                  0                  0                  0  
2                  0                        1                  0                  0                  0  
+  
+ Total execution time (One-Hot Encoding)  
+ -----  
0.0127 seconds  
+ =====
```

Como en el Dataset original, cada producto se contaba en una sola fila, pero las columnas de usuarios y reseñas contenían listas de elementos separados por comas (por ejemplo, 8 usuarios en una misma celda).

Al aplicar la explosión para separar la lista de categoría y poder cruzarlas:

- Si un producto tenía 8 reseñas, su fila se duplicó 8 **veces** (una por cada reseña/usuario).
- Al ejecutar la extracción de categorías sobre ese Dataset ya transformado, el análisis no está contando *productos únicos*, sino **las filas totales resultantes**.

Para poder ver esto, debemos ejecutar de nuevo el análisis mediante la función:

```
GetCategories(pDfIn: pd.DataFrame)
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

```
+ =====  
+ Category Transformation - Main Category Extraction  
+ -----  
+ Volumen de nuevas categorías principales únicas: 9  
+  
+ Distribución de productos por categoría raíz:  
Electronics          4095  
Computers&Accessories 3595  
Home&Kitchen         3513  
OfficeProducts       248  
MusicalInstruments   16  
HomeImprovement      16  
Toys&Games           8  
Car&Motorbike        8  
Health&PersonalCare  4  
Name: count, dtype: int64  
+  
+ Total execution time (Category Transformation)  
+ -----  
0.0122 seconds  
+ =====
```

En resumen, el volumen total de registros asciende a 11.503 debido a la expansión (explosión) de las listas de usuarios y reseñas, reflejando el peso real de cada categoría en el histórico de interacciones.




Figura 2b

Análisis y hallazgos [-Ir al índice-](#)

Auditoría de Calidad y Consistencia del Dataset [-Ir al índice-](#)

El objetivo técnico principal de esta auditoría es comprobar la consistencia del Dataset calculando la discrepancia existente por cada producto y verificando que el número real de interacciones agrupadas en las celdas **review_id** coincide con la métrica cuantitativa **rating_count**.

```
+ =====  
+ Data Quality & Veracity Audit Results  
+ -----  
+ Analyzed products: 1351  
+  
+ Sample of products with greater discrepancy (Potential wrong data):  
  
  product_id  tot_rev  tot_rat  abs_diff  percen_dev  
137  B014I8SSD0      8  426973  426965  99.998126  
138  B014I8SX4Y      8  426973  426965  99.998126  
356  B07KSMBL2H     16  426973  426957  99.996253  
318  B07GQD4K6L      8  363713  363705  99.9978  
317  B07GPXXNNG      8  363713  363705  99.9978  
232  B071Z8M4KX      8  363711  363703  99.9978  
  
+ Total Reviews Processed: 11503  
+ Total Ratings declared in origin: 23802423  
+ Real coverage of the dataset: 0.05%  
+ -----  
+ Total execution time (Audit)  
+ 0.0217 seconds  
+ =====
```

Tras realizar la transformación de granularidad y ejecutar la verificación cruzada entre las interacciones extraídas de las columnas **user_*** (ID y name), **review_*** (ID, title y content) y las métricas de **rating_count**, puedo extraer las siguientes conclusiones:

Que este método de comprobación de calidad y veracidad del dato no es fiable —*casi diría que he perdido el tiempo pero no, se obtiene otras conclusiones*— Así que descarto el uso de técnicas de Minería de Texto para modelar el comportamiento de usuario mediante las columnas **user_name**, **review_content**, **review_title**, debido a la bajísima representatividad de los datos, **0.05%** de cobertura frente al volumen global de valoraciones. Parece que la extracción de información para construir el Dataset hubiese sido mediante *web scrapping*, lo que evidencia que esos campos de texto están severamente restringidos por un posible cuello de botella técnico en la extracción.

Según el análisis anterior, nos enfrentamos a una limitación de origen al haberse guardado los textos de los comentarios separados por comas sin un entrecomillado calificado ("comentario 1", "comentario 2"), por tanto *la información de dónde termina una reseña y dónde empieza otra se ha fusionado de forma irreversible*, por lo que estas columnas de texto no aportan valor, por lo que incluso me atrevería a decir que podemos eliminarlas para los análisis en adelante.

Las variables numéricas como **rating**, **rating_count**, **actual_price**, **discount_percentage**, y **discounted_price** se confirman como consistentes, masivos y estadísticamente significativos.

Ante esto y a mi juicio, me decanto por analizar métricas cuantitativas (precios, valoraciones y cantidad de reseñas).

Trazabilidad de Reseña Única (user_id + review_id + product_id) [-Ir al índice-](#)

Por política de negocio y diseño relacional en plataformas de e-commerce, la relación entre un usuario y la reseña de un producto específico debe ser de **1 a 1**. Un cliente real solo puede emitir una reseña (**review_id**) para un artículo concreto (**product_id**). Por tanto, en un Dataset limpio y explotado, la combinación de **product_id + user_id + review_id** no debería repetirse nunca; su cuenta máxima debe ser 1.

Como ya no me fío de la veracidad de este Dataset por motivos anteriormente comentados, como por ejemplo que su procedencia o la captura de sus datos haya sido mediante *web scrapping* —*que este método falla más que una escopetilla feria*— Tenemos que comprobar si el Dataset respeta esta regla, así que le vamos a pedir muy amablemente a Pandas agrupe el dataset por esas dos variables (**product_id** y **user_id**) y cuente cuántas veces aparece **review_id**. Si nos devuelve más de 1, claramente la regla está rota.

Ejecutando el siguiente análisis...

```
# =====  
# DataFrame AuditDuplicatesRevsByUserAndProds  
# -----  
# Revisa la duplicidad relacional entre usuarios y productos para detectar inconsistencias en el conteo de  
# reseñas  
#  
# @param DataFrame pDfIn DataFrame donde buscar duplicidades.  
# -----  
def AuditDuplicatesRevsByUserAndProds(pDfIn: pd.DataFrame):  
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Podemos comprobar el siguiente resultado

```
+  
+ =====  
+ Duplicated Reviews by Product & User  
+ -----  
+ Relational control metric: 3  
+  
+ product_id      user_id      review_id  rating  actual_price  
46  B002PD61Y4  AGA2PZGWMQIRA46VYOTICFE7KCBA  R2EJIN3N3L3XKI      4.1      1208.0  
881  B002PD61Y4  AG7QMBEFFY2LJJKKEVWMJU2BMNRQ  R3B09D050WHWVX      4.1      1208.0  
881  B002PD61Y4  AGMG74N6WQGI376W7GEJJ4XD3ARQ  R10KVN4LSVD459      4.1      1208.0  
881  B002PD61Y4  AEHQQTEDMSXRGSDDEIH3JF4AOMQ  R1MLGZDQDKIVIF      4.1      1208.0  
881  B002PD61Y4  AETRIARSUFSMNG5LFJZMW6CBJMMQ  R2LOAPI3SK4RCX      4.1      1208.0  
...      ...      ...      ...      ...  
1018 B0BMXMLSMM  AHFENRYJG4LPXDTUGEMG335VICSQ  R14ZOPYFH0YYRQ      4.5      999.0  
88  B0BMXMLSMM  AFKDGUQ5TMGT3PXBHAWPRE5CACQ  R347KU67LE6JEH      4.5      999.0  
88  B0BMXMLSMM  AGJOGZAGBMX7PBCUAILD2YIM5MAA  R2782FIPC5T4KM      4.5      999.0  
88  B0BMXMLSMM  AHHT4VWMFYASASNW6RH2Q65C6YNDA  RA1PNAU355MLG      4.5      999.0  
88  B0BMXMLSMM  AHWENSYYF2QDH3EX4REMVGEBEMMLQ  RMGA8IGV2WQDX      4.5      999.0  
  
[1622 rows x 5 columns]  
+  
+ Total execution time (Audit duplicates)  
+ -----  
0.0655 seconds  
+ =====  
+
```

Podemos observar que hay muchísimos duplicados y como queremos que la calidad del Dataset sea lo más precisa posible para asegurarnos que el análisis posterior sea matemáticamente fiable y poder presentar informes fiables, debemos limpiar este ruido.

Se podría pensar que esto es un claro indicativo de Fraude. Investigando un poco aparece el **Astroturfing** (*creación coordinada de una falsa opinión pública masiva*), en este contexto sería disparar artificialmente el **rating_count**.

Si observamos con atención la salida, podemos ver que el índice **881** aparece cuatro veces seguidas en el recorte, pero mostrando usuarios diferentes y reseñas diferentes:

	product_id		user_id		review_id	rating	actual_price
	...		...		...	...	...
881	B002PD61Y4	AG7QMBEFFY2LJJKKEVWMJU2BMNRQ	R3B09D050WHWVX	4.1	1208.0		
881	B002PD61Y4	AGMG74N6WQGI376W7GEJJ4XD3ARQ	R10KVN4LSVD459	4.1	1208.0		
881	B002PD61Y4	AEHQQTEDMSXRGSDDEIH3JF4AOMQ	R1MLGZDQDKIVIF	4.1	1208.0		
881	B002PD61Y4	AETRIARSUFSMNG5LFJZMW6CBJMMQ	R2LOAPI3SK4RCX	4.1	1208.0		

Si la función que hemos ejecutado aísla las filas de usuarios que se repiten, ¿por qué aparecen ahí usuarios totalmente distintos compartiendo el índice 881?

Lo que ocurre aquí es que en el archivo original, la fila 881 esta duplicada, muy probablemente por el método de extracción de información, y que ya he comentado que falla más que funcionar, *web scrapping*, y no es que el método falle si no que lo que falla es la programación en sí.

Por ejemplo, pensemos que la fila 881 original de Amazon contenía un producto con una lista de 50 comentarios de 50 personas distintas. Si el *scraper* capturó esa fila varias veces por error, al ejecutar el `.explode()`, las 50 personas se multiplican automáticamente.

Si queremos una seguridad del 100% para separar los errores de captura de los posibles fraudes por *Astroturfing*, vamos a ejecutar el siguiente análisis:

```
# =====
# DataFrame AuditPotentialFraud
# -----
# Detecta posibles casos de fraude separando la cuenta de códigos de reseña para cada par de usuario y
# productos distintos tiene asociados, que deberían ser todos o la inmensa mayoría. Por el contrario,
# si hay pares con múltiples códigos de reseña distintos, es un indicio de posible manipulación o
# fraude en las reseñas.
#
# @param DataFrame pDfIn DataFrame donde buscar.
# -----
def AuditPotentialFraud(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

```
+
+ =====
+ Potential Fraud Detection counting Reviews by Product & User
+ -----
+ Pairs with SAME ID review (Technical error): 10593
+ Pairs with DIFFERENT review IDs (Potential Fraud): 1
+
+ Total execution time (Audit Potential Fraud)
+ -----
0.0209 seconds
+
+ =====
+
```

Para interpretar esto, si el 100% (o casi) cae en "Error Técnico", podemos afirmar con total seguridad que las filas son un subproducto analítico causado por la redundancia de volcado en el Dataset original.

Por el contrario, si aparece algo en "Posible Fraude" serían casos anómalos donde un mismo ID de usuario escribió dos textos con IDs de reseña distintos para el mismo producto o reseñas sobre variantes del mismo artículo, como comprar el mismo modelo de camiseta en azul y en negro.

Depuración de duplicados relacionales -Ir al índice-

Para garantizar la integridad estadística del análisis y evitar que único usuario tenga más de una reseña sobre el mismo producto, se ha aplicado el criterio de exclusión estricto basado en la regla de negocio relacional del ecosistema general que es **1 usuario, 1 reseña por producto**.

```
# =====
# DataFrame CleanRelationalDuplicates
# -----
# Elimina las filas redundantes provocadas por la duplicidad de capturas en el Dataset de origen.
#
# @param DataFrame pDfIn DataFrame donde buscar.
# @return DataFrame df DataFrame sin las filas redundantes.
# -----
def CleanRelationalDuplicates(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Tras eliminar las redundancias técnicas de captura, se ha ejecutado una limpieza final que garantiza que la métrica de control relacional máxima sea estrictamente 1.

```
+
+ =====
+ Cleaning relational duplicates
+ -----
+ Total records before cleaning: 10595
+ Total records after cleaning: 10594
+
+ New relational control metric: 1
+
+ Total execution time (Cleaning relational duplicates)
+ -----
+ 0.0304 seconds
+ =====
+
```

Verificación de duplicados relacionales [-Ir al índice-](#)

Vamos a lanzar la siguiente función para poder verificar y a la misma vez identificar que el método de depuración de duplicados ha limpiado satisfactoriamente el Dataset y que se mantenga la regla de **1 usuario, 1 reseña por producto**.

```
# =====
# DataFrame CheckRelationalDuplicates
# -----
# Identificar las combinaciones (Producto, Usuario) que siguen teniendo más de 1 registro
#
# @param DataFrame pDfIn DataFrame donde buscar.
# -----
def CheckRelationalDuplicates(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

```
+
+ =====
+ Check relational duplicates
+ -----
Empty DataFrame
Columns: [product_id, user_id, review_id, rating]
Index: []
+
+ Total execution time (Check relational duplicates)
+ -----
+ 0.0409 seconds
+ =====
+
```

Auditoría de datos Null [-Ir al índice-](#)

Para hacer un análisis sobre los datos faltantes o Null, vamos a usarla siguiente la función:

```
# =====
# DataFrame AuditNullValues
# -----
# Identifica el volumen y porcentaje de valores nulos en el dataset
#
# @param DataFrame pDfInput DataFrame expandido y procesado regionalmente.
# @return DataFrame Resumen estadístico de las columnas que contienen datos ausentes.
# -----
def AuditNullValues(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Observando el resultado del análisis en consola...

```
+ =====
+ Null Values & Missing Data Integrity Audit
+ -----
+ Columns with missing data detected: 2
+      null_values  null_perce
rating           8      0.069547
rating_count      2      0.017387
+
+ Total execution time (Null Audit)
+ -----
0.0266 seconds
+ =====
```

...podemos ver que el volumen de datos ausentes es completamente residual:

- Columna **rating** con solo 8 registros nulos (insignificante **0.069%** del total).
- Columna **rating_count** en la que únicamente se encuentran 2 registros nulos (**0.017%** igual que el anterior).

Entiendo que con este resultado, la estrategia a seguir en cuanto a la calidad y limpieza del Dataset se refiere, a mi juicio, será la borrar directamente los registros afectados.

Investigando en la gran enciclopedia de la red, es decir Internet, —*ya sabemos que si preguntamos a Google responde Gemini*— dice que:

“En la metodología de Minería de Datos, cuando la pérdida de información en variables métricas es inferior al 1%, la estrategia óptima, más segura y transparente es la eliminación directa de los registros afectados (listwise deletion).”

También entiendo que intentar aplicar técnicas de estadística como sustituir por la media, o la mediana, en un volumen tan minúsculo no nos aportará ningún beneficio; al contrario, correríamos el riesgo innecesario de introducir ruido. Por lo que borrarlas, garantizamos un modelo 100% real si lo que estamos buscando en *analizar la percepción del cliente sobre los productos a partir de sus valoraciones* como dejamos claro en el apartado de [Objetivo del proyecto](#). Usaremos la función desarrollada para sanear, limpiar, refinar o purgar los datos cuyos valores son nulos.

```
# =====
# DataFrame PurgeNullValues
# -----
# Elimina de forma estricta los registros que contienen valores nulos en columnas métricas
#
# @param DataFrame pDfIn DataFrame con valores ausentes detectados.
# @return DataFrame DataFrame saneado sin filas huérfanas en las columnas críticas.
# -----
def PurgeNullValues(pDfIn: pd.DataFrame):
    ... Código ...
```

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)

Obteniendo el siguiente resultado donde el Dataset se ajusta reduciendo un puñado de filas y quedando lo más limpio posible.

```
+ =====
+ Executing Deletion for Missing Metrics
+ -----
+ Initial records before purge: 11503
+ Orphaned records removed: 10
+ Dimensions of final cleaned dataset: (11493, 17)
+
+ Total execution time (Purge)
+ -----
0.0061 seconds
+ =====
```


Minería de datos [-Ir al índice-](#)

Estructura de Catálogo de Precios [-Ir al índice-](#)

Además de la primera observación preliminar del Dataset, en cuanto a la segregación mediante (,) de las columnas **user_id**, **user_name**, **review_id**, **review_title** y **review_content**, también se observó la clara y abismal dispersión entre valores mínimos y máximos en los datos. Más aún cuando al limpiar los símbolos de moneda (₹) y convertir los precios a formato numérico, saltó a la vista que el Dataset mezcla en las mismas columnas productos radicalmente distintos. Conviven artículos de apenas 100 rupias (como cables o fundas) con tecnología de consumo de más de 60.000 (como portátiles o televisores).

Todo esto ha propiciado que dibujemos un gráfico —*al principio me decanté directamente por un Boxplot*— con las variables cuantitativas **actual_price** y **discounted_price**, como ya comenté en el apartado sobre la [consistencia del Dataset](#), pero apareció una barra gigante al principio y el resto completamente vacío (*ver Figura 3a izquierda*).

Como en este caso no creo que ese tipo de gráfico de mucho a la imaginación analítica, al cambiar por un Scatterplot, con su forma resultante, por así decirlo, de vaso de 7-up, con muchas burbujas abajo y unas pocas arriba (*ver Figura 3a derecha*), o dicho de otro modo para que realmente se entienda el gráfico: una base masiva de artículos de bajo coste, con la contrapartida que los artículos Premium se representan en la parte superior como una fracción mínima



La franja densa es el grueso de los productos de consumo masivo (cables, fundas, accesorios, pequeños utensilios) y de bajo coste, como ya hemos comentado, que se mueven entre las ₹300 y las ₹2.000. Por eso se ve una masa compacta de puntos.

Las "burbujas" de arriba (los Casos atípicos), esos puntos que flotan alto (los que rozan las ₹139.900) no son errores de datos. Son productos caros reales categorizados en SmartTelevision, Laptops, Smartphones.

Todo lo visto aquí no quita el hecho que con el Scatterplot se observa claramente la dispersión de los productos y los posibles valores atípicos, pero me propuse mostrar la dispersión real mediante la **escala logarítmica** (*ver Figura 3b*)

Visual Audit of Price Distribution and Outliers (Logarithmic Scale)




Figura 3b

Al activar la escala logarítmica, cambiamos la perspectiva “de la lupa”. En lugar de ver “distancia en rupias”, estamos viendo **órdenes de magnitud**, como son por ejemplo: saltos de diez en diez: 10, 100, 1.000, 10.000, 100.000.

Ahora que tenemos comprimidas visualmente las frecuencias más altas, esta escala permite auditar el catálogo completo en una sola gráfica, haciendo visibles los productos de más bajo coste y los productos Premium, y mostrando cómo se reparten realmente los precios sin que la gama baja esconda al resto.

El análisis bajo escala logarítmica permite identificar la verdadera naturaleza de la política de precios del catálogo, desmontando falsos positivos de errores de datos:

El Núcleo del Catálogo, el consumo masivo [-Ir al índice-](#)

El 75% de los productos analizados se sitúa por debajo de las ₹4,295.00, concentrándose la gran masa crítica del Dataset (la franja densa inferior de la gráfica de dispersión) entre las ₹300.00 y las ₹2,000.00. Esto coincide de forma coherente con la alta densidad de las categorías *Home&Kitchen* y accesorios informáticos básicos.

Naturaleza de los Casos atípicos coherentes [-Ir al índice-](#)

La presencia de un valor máximo extremo de **₹139,900.00** destaca de forma aislada en la parte derecha del gráfico. Aunque en términos globales se comporta numéricamente como un *valor atípico severo*, al cruzarlo con la segmentación obtenida en la transformación de categorías se constata que pertenece a la familia de *Electronics* (específicamente SmartTelevisions).




Figura 4

Con esta gráfica ([Figura 4](#)) cruzamos las dos cosas que hemos analizado por separado: el precio y las categorías.

Al mostrar los rangos de precio de cada sección, dejamos muy fácil y visualmente resuelto que los productos atípicos caros pertenecen casi en su totalidad a *Computers* y *Electronics*, justificando hacer [marketing de nicho](#) solo en esos sectores.

Conclusiones -Ir al índice-

Los valores extremos superiores no constituyen anomalías de tipografía o errores de extracción del CSV, sino que representan la dispersión natural y real de la categoría *Electronics* y *Computers&Accessories*. Por tanto, **se determina no eliminar estos registros** del dataset, ya que la inclusión de las variables binarias del One-Hot Encoding (cat_Electronics, etc.) dotará al modelo de la capacidad contextual necesaria para entender que un precio de seis cifras es perfectamente válido y representativo dentro de ese sector tecnológico.

El gráfico revela cómo se comporta la política de precios de los vendedores en Amazon. Te permite certificar si la plataforma se sostiene sobre un volumen masivo de productos de bajo coste con márgenes pequeños, o si el grueso de los ingresos depende de los impactos de la gama alta.

De cara a la Minería de datos, este análisis es crítico.

Los algoritmos basados en distancias matemáticas se desvirtúan si se dejan los precios en bruto; una diferencia de 5.000 rupias en un ordenador parecería insignificante para el modelo frente a los valores máximos del Dataset, mientras que esa misma diferencia destruiría cualquier lógica al analizar los accesorios de 200 rupias.

*Los gráficos y el resumen estadístico de muestra que es obligatorio aplicar una **normalización** o un **escalado de datos** como esta conversión logarítmica a las columnas **actual_price** y **discounted_price** antes de entrenar cualquier modelo de IA predictivo o de clasificación, o minería.*

Recomendaciones -Ir al índice-

Auditoría de Popularidad para la Asignación de Presupuesto (Evitar Falsos Éxitos)

Acción de negocio

Antes de asignar presupuesto publicitario para promocionar los productos estrella, el departamento de Marketing debe cruzar el volumen de valoraciones (**rating_count**) con la lista limpia de usuarios únicos (**user_id**).

Esto evitará invertir dinero en productos que parecen un éxito masivo en la plataforma, pero que realmente tienen una popularidad inflada por registros duplicados. Asegura que el presupuesto de anuncios se concentre solo en productos con clientes reales.

Estrategia de Venta Cruzada para el Núcleo del Catálogo (Consumo Masivo)

Acción de negocio

Crear campañas de volumen, packs de productos y recomendaciones automáticas en el proceso de pago para los artículos de la gama baja (cables, fundas y accesorios).

El análisis de dispersión demuestra que el 95% del catálogo está concentrado en este rango inferior ([Figura 3a](#)). Como estos artículos tienen un precio de venta muy bajo, la estrategia no debe buscar el margen de beneficio por unidad, sino aumentar el ticket medio del cliente haciendo que compre varios accesorios juntos.

Segmentación de Alta Tecnología para los Casos Atípicos Coherentes (Gama Alta)

Acción de negocio

Diseñar campañas de marketing de nicho altamente específicas para los productos de precio elevado (portátiles y televisores), eliminando estos artículos de las promociones masivas o generalistas.

Estos productos son las "burbujas" que flotaban aisladas en la parte alta ([Figura 3a](#)) y derecha ([Figura 4](#)) de las gráficas. Al ser artículos caros y escasos en el Dataset, requieren una campaña de comunicación enfocada en la confianza, la financiación y las especificaciones técnicas, por lo que la publicidad debe ir dirigida exclusivamente al público objetivo que busca activamente renovar su tecnología.

Limitaciones [-Ir al índice-](#)

Calidad del texto en las reseñas

Una de las principales limitaciones del Dataset es el formato de las columnas de texto (***review_content*** y ***review_title***) en el origen del mismo.

Presentan un sesgo de truncado crítico (0.05% de cobertura), solo muestran entre 8 y 16 elementos testimoniales por registro y al estar agrupados con coma (,) dentro de una misma celda, su separación no puede llevarse a cabo ya que es propensa a errores gramaticales. ¿El motivo? Existen caracteres coma (,) gramaticales dentro del texto y sería imposible hacer una separación limpia sin que haya incoherencias. Por ello, se limitó su uso y el análisis se centró en las dimensiones numéricas y de identidad (***user_id***, ***rating***).

Ausencia de datos temporales o de coste

Al denominarse literalmente "Conjunto de datos de ventas de Amazon", el Dataset es bastante escaso en incluir fechas de compra, fechas de venta, ni costes de adquisición. Vamos tan escaso como que no existen, lo que impide realizar un análisis de evolución temporal de las ventas o calcular el margen de beneficio real neto.

Conclusiones [-Ir al índice-](#)

Importancia de la auditoría de datos

Aunque esto es obvio y el ser humano muy propenso a olvidar y tropezar incontables veces sobre lo mismo, creo que debería incluirse en todo informe de Auditoría de Big Data a la hora de exponer Recomendaciones ya que en todo proyecto KDD, y cuando digo todo no creo que haya una cifra más baja del 99,98%, **se demuestra que no se pueden aplicar algoritmos ni diseñar estrategias de marketing directamente con los datos en bruto**. De no limpiar los registros duplicados, los conflictos de granularidad en los usuarios, normalización de importes, cantidades, etc; cualquier departamento que solicite informe, habría diseñado campañas basadas en datos incoherentes y falsos éxitos.

Validación del enfoque cuantitativo

Al quedar descartado el análisis de los textos por su falta de consistencia, el valor real de este informe se concentra en sus datos numéricos. Las variables de precio, puntuación (***rating***) y volumen de valoraciones (***rating_count***) son estadísticamente fiables, lo que justifica que hayamos centrado todo el estudio en la analítica cuantitativa y en modelos de precios.

Realidad del inventario analizado

Los análisis de distribución dejan claro que el catálogo no es equilibrado. Está totalmente sobrecargado por productos de consumo masivo y bajo coste como hemos visto: cables, fundas y accesorios económicos, dejando la tecnología de gama alta, véase portátiles o televisores, como excepciones aisladas dentro del volumen total de referencias.

Anexo [-Ir al índice-](#)

Ver cuaderno de Python en [GitHub](#) o también, [descarga directa del cuaderno](#)